

QUANTA FLOW

Defesa Técnica & Contexto de Integração HERMES

Contexto unificado para ferramentas de IA — Estado real do sistema

v7.4.0 · 27/05/2026, 16:42 (BRT)

"Sistema nervoso digital de ecossistemas de negócios"

202

endpoints REST

14

módulos ativos

5

canais omnichannel

100%

TypeScript

O Quanta Flow é uma plataforma SaaS multitenante de automação omnichannel que atua como o sistema nervoso digital de ecossistemas de negócios. Pense nela como um HubSpot + ManyChat com IA embutida e código 100% próprio: você configura flows visuais, dispara campanhas segmentadas, acompanha contatos em pipelines do CRM e engaja usuários com trilhas de microlearning e gamificação — tudo em tempo real via REST API + WebSocket.

Diferente de ferramentas SaaS estrangeiras cobradas em dólar, o Quanta Flow é uma infraestrutura nativa, multitenant, extensível e auditável — hospedada e controlada pelo próprio negócio.

1.1 Diferenciais Competitivos

- Omnichannel nativo: WhatsApp (3 providers), Telegram, Instagram, Email — uma única inbox, um único pipeline.
- Visual Flow Builder: canvas drag-and-drop com 10 tipos de bloco, geração por IA e 5 templates built-in.
- IA Brain: insights preditivos de conversão, ações 1-clique (mover pipeline, atribuir agente, disparar trilha).
- Score Engine gamificado: pontos, badges, cooldowns e thresholds configuráveis por regra.
- Mobile app nativo (Expo/React Native): Login, Inbox, CRM e Dashboard — mesmo backend, JWT compartilhado.
- Multi-tenancy com RBAC completo: 18 permissões × 7 recursos, isolamento por workspaceId em todas as rotas.
- Substituição de HubSpot + ManyChat: stack Node.js/PostgreSQL/React gerenciada nativamente sem contratos em dólar.

1.2 Stack Técnica

Camada	Tecnologia
Backend	Express 5 + Node.js 24, esbuild, TypeScript strict
Banco de Dados	PostgreSQL + Drizzle ORM (type-safe), migrações automáticas
Frontend Web	React 18 + Vite + Tailwind CSS v3 + Shadcn UI + Wouter
Mobile	Expo SDK 54 + Expo Router + React Native New Architecture
Realtime	Socket.io namespace /inbox — mensagens + delivery status
Auth	JWT 24h + bcrypt + tokenVersion (invalidação imediata)
IA	OpenAI (gpt-4o-mini, tts-1, dall-e-3) via Replit AI Integrations
Voz/Vídeo	ElevenLabs (eleven_multilingual_v2) + HeyGen (/v2/video/generate)
Monorepo	pnpm workspace: api-server, quanta-flow, quanta-flow-mobile, mockup-sandbox

O Hermes é o núcleo de inteligência agêntica que transforma o Quanta Flow de uma plataforma de automação em um ecossistema verdadeiramente autônomo. Enquanto o Quanta Flow provê a infraestrutura (canais, CRM, flows, campanhas), o Hermes injeta raciocínio profundo, memória persistente e aprendizado contínuo em cada interação.

2.1 Componentes do Framework HERMES

SOUL.md — Alma e Personalidade	PLANEJAR
Define a identidade ética do agente: restrições de atuação, tom de voz, valores e limites por nicho de negócio. Essencial para áreas reguladas (saúde, jurídico, psicologia) onde escuta ativa e profissionalismo são mandatórios. Configura o "modo de ser" do agente, não apenas o que ele faz.	
MEMORY.md — Memória Persistente	PARCIAL
Permite ao agente lembrar o histórico completo de interações por canal (WhatsApp, Telegram, Instagram). Integra-se ao CRM do Quanta Flow (tabela omnichannel_messages) para garantir continuidade de contexto entre sessões, eliminando a necessidade de o lead repetir informações.	
SKILLS.md — Habilidades Autônomas	PLANEJAR
Repositório de habilidades que o agente gera e acumula a partir da resolução de problemas práticos. Cada skill é uma unidade de conhecimento reutilizável: "como qualificar um lead frio no setor de saúde", "como converter objeção de preço", etc. Conecta-se ao Self-Improving Loop.	
HERMES.md — Contexto Mestre	PLANEJAR
Arquivo de configuração que orquestra SOUL + MEMORY + SKILLS. É o system prompt estruturado que qualquer ferramenta de IA recebe para operar dentro do ecossistema Quanta Flow com pleno conhecimento do contexto do negócio, regras e histórico.	
Self-Improving Loop	PARCIAL
Ciclo fechado de aprendizado: o agente resolve uma interação !' gera uma nova skill !' armazena em SKILLS.md !' usa na próxima interação similar. O BrainWorker (já implementado) é o ponto de entrada natural para este loop no Quanta Flow.	

2.2 Integração HERMES x Quanta Flow

O ponto de entrada natural do Hermes no Quanta Flow são os Agentes de IA (já implementados). Cada agente pode ser configurado com seu SOUL.md via campo "instructions" e acessar o MEMORY.md via a tabela omnichannel_messages do CRM. O BrainWorker (5min) é o motor natural do Self-Improving Loop.

Componente HERMES	Módulo Quanta Flow	Status
SOUL.md (persona/ética)	Agentes IA !' campo instructions	PARCIAL — campo existe, arquivo formal não
MEMORY.md (memória)	CRM !' omnichannel_messages	OK — dados disponíveis, integração formal pendente
SKILLS.md (habilidades)	BrainWorker + audit_logs	PLANEJAR — estrutura base existe
Self-Improving Loop	BrainWorker (5min interval)	PLANEJAR — worker existe, loop não implemetado
HERMES.md (orquestrador)	System prompt dos Agentes	PLANEJAR — depende de SOUL + MEMORY + SKILLS

2.3 Arquitetura de Tráfego Pago Agêntico

O Quanta Flow + HERMES operam em 4 camadas

Camada	Agente/Tecnologia	Função	Status
1. Atração	Google PMax & Meta Advantage+	Distribuição autônoma de anúncios por orçamento e audiência	PLANEJAR
2. Recepção	Inbox Omnichannel (WebSocket)	Intercepta o lead instantaneamente, triagem humanizada via IA	OK
3. Conversão	CRM + Google Calendar	Pipeline, agendamentos, integrações REST API	PARCIAL
4. Retenção	Microlearning + Score Engine	Trilhas de conhecimento + pontos + badges	OK

O Quanta Flow possui atualmente 14 módulos ativos, 202 endpoints REST e cobertura total de WebSocket em tempo real. Abaixo o mapa completo de features por módulo:

3.1 Autenticação & Multi-Tenancy

Feature	Status	Notas
Login JWT 24h + bcrypt	OK	Invalidação imediata via tokenVersion
Logout + forgot password	OK	Email transport configurável
Roles (super_admin, admin, user)	OK	Seed automático no boot
18 permissões × 7 recursos (RBAC)	OK	middleware checkRole/checkPermission
Audit log de alterações	OK	Tabela audit_logs
Multi-tenant Workspaces (F39)	OK	JWT carrega workspaceId
Workspace switcher (web + mobile)	OK	Reemite JWT no switch
Filtragem efetiva por workspaceId	PARCIAL	Slice 2 — evolução futura

3.2 Inbox Omnichannel

Feature	Status	Notas
WhatsApp Z-API	OK	Webhook auto-config
WhatsApp Baileys (sessão local)	OK	@whiskeysockets/baileys
WhatsApp Meta Cloud API	OK	Graph API v19.0
Telegram Bot	OK	Telegram Bot API
Instagram DM	OK	Meta Graph API
Email SMTP/IMAP	OK	Nodemailer por usuário
Real-time Socket.io (/inbox)	OK	Mensagens + delivery status "d500ms
Fila de Atendimento + SLA	OK	Timer SLA com webhook ao expirar
Status de entrega (sent/delivered/read)	OK	Ack handlers Z-API + Evolution

3.3 CRM & Contatos

Feature	Status	Notas
Contatos unificados omnichannel	OK	unified_contacts + contact_identifiers
Timeline omnichannel completa	OK	omnichannel_messages agregado
Pipeline customizável por usuário	OK	pipeline_stages drag-and-drop
Kanban + filtros (temperatura, intenção)	OK	—
AI intent summary por contato	OK	gpt-4o-mini
Atribuição manual + round-robin	OK	agent_assignments
Quick replies	OK	Atalhos de texto

3.4 Visual Flow Builder

Feature	Status	Notas
Canvas React Flow drag-and-drop	OK	—
10 tipos de bloco	OK	text, tts, image_ai, delay, condition, ai_agent, webhook, queue, resolve, update_lead
Geração de fluxo via IA	OK	gpt-4o-mini !' JSON validado
5 templates built-in	OK	Seed automático
Export/Import JSON + versionamento	OK	—
Variáveis interpoladas	OK	{nome}, {telefone}, {email}

Proteção contra ciclos (max 50 steps)	OK	—
---------------------------------------	----	---

3.5 IA — Agentes, Brain & Intent

Feature	Status	Notas
Intent detection automático	OK	gpt-4o-mini inline em messageProcessor
Auto-score de leads	OK	Atualiza temperature por contato
Fábrica de Agentes (CRUD)	OK	/api/admin/agents
Chat preview por agente	OK	gpt-4o-mini
TTS por agente (tts-1)	OK	/api/admin/agents/:id/tts
Avatar generator (dall-e-3)	OK	/api/admin/agents/generate-avatar
IA Brain — insights de leads estagnados	OK	GET /api/brain/insights
Predição de conversão on-demand	OK	GET /api/brain/insights/:id/prediction
Ações 1-clique (pipeline, agente, trilha)	OK	POST /api/brain/actions/*
BrainWorker (5min)	OK	Emite Socket.io brain:new-insight

3.6 Campanhas, Microlearning & Score

Feature	Status	Notas
Wizard 4 passos	OK	Segmento !' conteúdo !' agendamento !' revisão
Drip sequences com delays	OK	CampaignWorker (60s)
Geração de copy via IA	OK	gpt-4o-mini
Métricas de campanha	OK	Envio/entrega/resposta/conversão
Trilhas de microlearning	OK	LearningWorker (5min), galtilho por stage/intent
Score engine + badges	OK	Regras configuráveis, cooldowns
Ranking gamificado	OK	Por score de contatos

3.7 Estúdio Social/Ads & Integrações

Feature	Status	Notas
Geração de conteúdo IA (6 formatos)	OK	headlines, caption, hooks, socialAds, email, blog
TTS ElevenLabs	OK	eleven_multilingual_v2
Vídeo HeyGen	OK	/v2/video/generate, polling assíncrono
UTM link builder	OK	source/medium/campaign
Google Sheets v4	OK	OAuth2
Outbound Webhooks HMAC-SHA256	OK	Push para sistemas externos
Calendário de publicação	OK	publication_schedules por data/canal

3.8 Mobile App (Expo)

Feature	Status	Notas
Artifact quanta-flow-mobile	OK	Expo SDK 54 + Expo Router, servido em /mobile/
Login JWT + SecureStore	OK	Fallback localStorage no preview
Workspace switcher mobile (F39)	OK	Header x-workspace-id em todas requisições
Dashboard (KPIs + IA Brain)	OK	GET /api/crm/dashboard + /api/brain/insights
Inbox mobile + chat	OK	FlatList invertida + KeyboardAvoidingView
CRM mobile + detalhes contato	OK	Lista com busca + timeline

Os itens abaixo representam funcionalidades planejadas ou parcialmente implementadas. Cada item está classificado por prioridade estratégica e impacto no ecossistema.

PRIORIDADE: CRÍTICO

■ HERMES.md — Arquivo de contexto mestre

Criar o HERMES.md como system prompt estruturado para todas as IAs do ecossistema. Ponto de partida: CLAUDE.md existente.

■ SOUL.md por nicho

Arquivo de ética/persona para cada vertical de negócio (saúde, jurídico, educação). Integrar ao campo "instructions" dos Agentes.

■ Filtragem multi-tenant (Slice 2)

Todas as queries já têm workspaceId no JWT, mas ainda faltam WHERE clauses em endpoints de CRM, flows e campanhas.

PRIORIDADE: ALTO

■ MEMORY.md — Integração formal

Estruturar a tabela omnichannel_messages como memória persistente formal do agente HERMES, com sumarização periódica (BrainWorker).

■ Self-Improving Loop

Implementar geração automática de skills no BrainWorker após interações bem-sucedidas. Base: audit_logs + brain/insights.

■ Google Calendar (Camada 3 — Conversão)

Integração OAuth2 com Google Calendar para agendamento direto pelo CRM. Pipeline !' Agendado.

■ Google PMax & Meta Advantage+

Webhooks/API de plataformas de anúncios para fechar o ciclo de atribuição: anúncio !' lead !' conversão !' receita.

PRIORIDADE: MÉDIO

■ Notificações push mobile

Expo Push Notifications para alertas de novos leads, mensagens e insights do IA Brain em tempo real no celular.

■ Landing Pages públicas

Builder drag-and-drop com 16 tipos de bloco, versionamento, métricas e submissões. Schema existe (landing_pages), UI pendente.

■ Dashboard de tráfego pago

Painel consolidado de métricas: CPL, CPC, ROAS, atribuição omnichannel — integrando dados de Meta, Google e inbox.

■ SKILLS.md — Repositório de habilidades

Estrutura de armazenamento e recuperação de skills geradas pelo Self-Improving Loop.

PRIORIDADE: FUTURO

■ Build EAS para lojas (iOS/Android)

O app Expo está pronto para build. Faltam credenciais Apple/Google e submissão às lojas.

■ WhatsApp Evolution API (full)

Provider Evolution API está parcialmente integrado. Completar ack handlers e webhook de status.

■ Relatórios exportáveis (PDF/CSV)

Exportação de dados de CRM, campanhas e score engine em formatos padronizados.

Este documento foi projetado para ser usado como contexto de entrada (system prompt ou RAG document) para ferramentas de IA que operam dentro do ecossistema Quanta Flow. A seguir, o guia de uso:

5.1 Como Usar Este Documento como Contexto IA

- **SYSTEM PROMPT BASE:** Inicie qualquer agente com "Você opera dentro do Quanta Flow v7.4.0 — uma plataforma SaaS omnichannel com os seguintes módulos ativos: [lista da Seção 3]."
- **RESTRIÇÕES ÉTICAS (SOUL.md):** Configure o campo "instructions" dos Agentes Quanta Flow com as restrições do nicho. Ex: "Você é um atendente de clínica de saúde. Nunca diagnostique. Sempre encaminhe para um profissional."
- **MEMÓRIA (MEMORY.md):** Injete os últimos N registros de omnichannel_messages do contato como contexto antes de cada resposta do agente.
- **SKILLS DISPONÍVEIS:** Liste as skills ativas no início do contexto para que o agente saiba quais ferramentas pode usar (ex: mover_pipeline, atribuir_agente, disparar_trilha).
- **ATUALIZAÇÃO AUTOMÁTICA:** O update-docs.ts regenera este documento a cada merge. Use sempre a versão mais recente disponível em /api/documentation/meta.

5.2 Endpoints de Acesso ao Contexto

Endpoint	Conteúdo
GET /api/documentation/meta	Metadados de todos os docs (versão, mtime, stamp)
GET /api/documentation/replit-md	Referência técnica completa (replit.md)
GET /api/documentation/changelog	Histórico de versões (CHANGELOG.md)
GET /api/documentation/claude-md	CLAUDE.md — diretrizes do agente
GET /api/documentation/tech/features	Catálogo de features (FEATURES.md)
GET /api/brain/insights	Insights IA em tempo real do CRM
GET /api/admin/agents	Lista de agentes configurados

5.3 Template de HERMES.md (Arquivo Mestre)

O arquivo HERMES.md (a ser criado) deve seguir esta estrutura mínima para a ferramenta de IA:

```
---
name: HERMES
version: 1.0.0
platform: Quanta Flow v7.4.0
---

# SOUL (Identidade e Ética)
Você é [nome do agente], [persona do negócio].
Restrições: [lista de restrições éticas do nicho].
Tom: [formal/informal/técnico/empático].

# MEMORY (Contexto do Contato)
Última interação: [data/hora]
Canal: [whatsapp/telegram/instagram]
Stage atual: [pipeline_stage]
Score: [pontuação atual]
Histórico resumido: [últimas 5 mensagens]

# SKILLS (Ações Disponíveis)
- mover_pipeline(contactId, toStage)
- atribuir_agente(contactId, agentId)
- disparar_trilha(contactId, trackId)
- enviar_mensagem(contactId, content)

# OBJETIVO
[objetivo específico da interação atual]
```

5.4 Benefícios Estratégicos e Viabilidade Financeira

- | | |
|--|---|
| ■ Ecossistema Omnichannel Consolidado | Captação centralizada em WhatsApp, Telegram, Instagram e Email — visão 360° em um único CRM com timeline unificada. |
| ■ Substituição de Custos em Dólar | Elimina contratos HubSpot (\$45-800/mês) + ManyChat (\$15-299/mês) por infraestrutura própria Node.js/PostgreSQL. |
| ■ IA Nativa sem Dependência | OpenAI via Replit AI Integrations — sem chave própria, cobrado por uso real. ElevenLabs e HeyGen para voz e vídeo. |
| ■ Gamificação como Retenção | Score engine + badges + microlearning aumentam engajamento pós-conversão e reduzem churn de leads frios. |

■ **Multi-Tenancy Escalável**

Uma instância atende múltiplos clientes/workspaces com isolamento completo de dados e RBAC granular.

■ **Ciclo Agêntico Fechado**

Com HERMES: o agente atrai (anúncios), recepciona (inbox), converte (CRM + calendar) e retém (microlearning) — sem intervenção manual.

